

[캡스톤디자인 결과보고서]

■ 연구과제

과제명 (작품명)	Occluded Point Clouds Classification via Point Clouds Completion (포인트 클라우드 컴플리션을 활용한 포인트 클라우드의 분류)	참여학기	2021년 2학기
--------------	---	------	-----------

■ 강좌정보

과목명	소프트웨어융합 캡스톤디자인	학수번호	SWCON401-00
과제기간	2021년 09월 01일 ~ 2021년 12월 31일	학점	3

■ 팀구성

팀명	Point2Vision		팀구성 총인원	1명
구분	성명	학번	소속학과	학년
대표학생	최명규	2017103762	소프트웨어융합학과	4
참여학생				

■ 지도교수 확인

지도교수	성명	황효석	직급	전임교수
	소속학과	소프트웨어융합학과	지도교수 확인	성명 : 황효석 (인)

■ 붙임

[첨부1] 과제 요약보고서

[결과물] 최종결과물 (최종작품 사진/도면/발표자료 등)

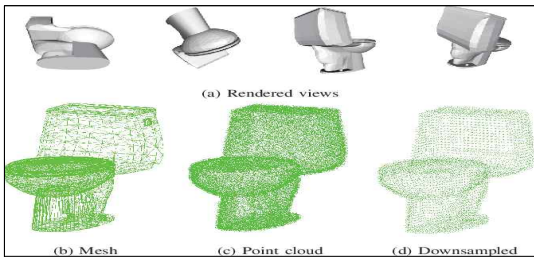
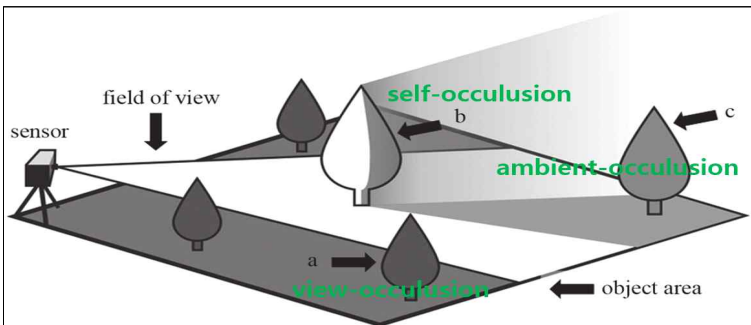
본 팀은 과제를 성실히 수행하고 제반 의무를 이해하여 이에 따른 결과보고서를 제출합니다.

일자 : 2021년 12월 21일

신청자(또는 팀 대표)

최명규 이현7

[캡스톤디자인 과제 요약보고서]

과제명	Point Clouds Classification via Point Clouds Completion (포인트 클라우드 컴플리션을 통한 포인트 클라우드의 분류)
<p>1. 과제 개요</p> <p>가. 과제 선정 배경 및 필요성</p> <p>포인트 클라우드(Point Cloud)는 3차원 공간상에서 (x, y, z)로 표현되는 점들의 집합으로 Lidar, RGB-D Camera 등과 같은 3D 센서로 측정된다. 최근 3D 센서의 발전으로 정밀한 포인트 클라우드를 측정할 수 있게 됨에 따라 이를 활용한 컴퓨터비전 연구가 활발히 진행되고 있다. 또한 3차원 복원(3D Reconstruction)이라는 과정 없이도 포인트 클라우드는 그 자체로 기하학적 모양(Shape)과 규모(Scale) 등 3차원 정보를 온전히 표현하고 있다는 장점을 지니고 있다. 더구나 최근 들어 급격하게 발전하고 있는 딥러닝 등과 같은 AI 기술을 기반으로 포인트 클라우드는 자율주행 자동차, 로봇릭스, 의료, SLAM 등 다양한 산업에서 당면하고 있는 3차원 컴퓨터비전 문제를 해결할 것으로 예측된다.</p> <p>이에 따라 학계에서도 포인트 클라우드를 컴퓨터비전 연구에 활용하려는 노력이 모이고 있다. 실제로 CVPR 등 저명한 컴퍼런스 제출되는 포인트 클라우드 관련 연구는 꾸준히 상승세이다. 특히 지난 2016년 CVPR에서 발표된 PointNet은 Symmetric Function과 Point-wise MLP을 통해 포인트 클라우드가 내재하고 있는 Unstructured, Unordered 문제를 획기적으로 해결해 주목을 받았다. 이에 따라 현재에도 PointNet을 기반으로 Point Cloud에 대한 다양한 컴퓨터비전 연구들이 진행되고 있다.</p> <div data-bbox="97 1173 633 1458">  <p>Figure2. CAD 모델 -> 포인트 클라우드</p> </div> <p>그러나 이러한 선행 연구들이 실제 환경에서 측정되는 포인트 클라우드에 실용적일까라는 질문에는 다소 의문이 존재한다. 이는 앞선 선행 연구 대부분이 포인트가 곡면을 따라 균일하게 분포된 완전한 포인트 클라우드(Complete Point Clouds)를 대상으로 연구를 진행했기 때문이다. 즉 이들 연구는 실제 환경에서 관측 가능한 포인트 클라우드가 아닌 기존 3D CAD 모델에서 임의의 추출한 포인트 클라우드를 데이터셋으로 선정하고 있다.</p> <p>우리가 실제 환경에서 관측할 수 있는 포인트 클라우드는 필연적으로 불완전하다. 이는 실제 환경에서 관측 가능한 포인트 클라우드는 언제나 완전한 포인트 클라우드의 부분집합이기 때문이다. 불완전 포인트 클라우드(Incomplete Point Clouds)는 노이즈(Noise), 해상도(Device-Resolution) 등과 같은 다양한 문제로 발생하며 그중 가장 큰 이유는 바로 가려짐(Occlusion) 문제이다. 가려짐은 사물의 일부만이 측정되는 현상으로 사물의 뒷면이 가려지는 Self-Occlusion, 센서의 시야각으로 초래되는 View-Occlusion, 장애물로 발생하는 Ambient-Occlusion으로 구분된다. 더구나 사물의 뒷면이 관측되지 않는 Self-Occlusion 현상은 단일 3D 센서에서 불가피하기 때문에 실제 환경에서 관측한 포인트 클라우드는 언제나 불완전한 형태로 측정되며 이에 따라 3차원 정보의 손실이 내재되어 있다고 볼 수 있다. 이는 완전한 포인트 클라우드를 대상으로 진행된 선행 연구들이 실제 환경에서 관측한 불완전 포인트 클라우드에서 좋은 성능을 내</p> <div data-bbox="671 1740 1426 2092">  <p>Figure3. 가려짐 현상</p> </div>	




Figure1. 포인트 클라우드 예시

지 못하는 데 가장 핵심적인 이유가 된다.




Figure4. 불완전한(가려진) 포인트 클라우드와 완전한 포인트 클라우드

나. 과제 주요내용

실제 환경에서 관측 가능한 포인트 클라우드는 필연적으로 불완전하기 때문에 앞선 선행 연구들이 제시하는 방법으로는 3D 컴퓨터비전 문제를 해결하는 것에는 한계가 존재한다. 즉 딥러닝 관점에서 이해하자면 완전한 포인트 클라우드로 학습된 모델은 실제 환경에서 관측된 불완전한 포인트 클라우드가 입력으로 주어졌을 때 성능 하락이 불가피하다. 즉 학습 성능을 보장할 수 없는 문제와 한계가 나타난다. 이러한 문제와 한계를 극복하고 불완전한 포인트 클라우드에서 실용적인 성능을 낼 수 있는 강건한 알고리즘을 구현하기 위해 이번 소프트웨어융합 캡스톤디자인에서는 포인트 클라우드 컴플리션(Point Clouds Completion)을 활용하는 방법에 관하여 탐구한다. 구체적으로 컴퓨터비전의 기본적인 과업으로 여겨지는 분류(Classification) 문제를 탐구 주제로 선정하여 불완전 포인트 클라우드의 분류 문제를 해결하고자 한다. 즉 포인트 클라우드의 컴플리션을 활용하여 실제 환경에서 관측한 불완전 포인트 클라우드의 분류 성능의 하락을 최소화하는 방법에 관하여 탐구한다.



Figure5. 생성에서 분류로 이어지는 2단계 구조

포인트 클라우드 컴플리션은 가려짐 현상으로 초래되는 불완전한 포인트 클라우드에서 완전한 포인트 클라우드로 생성하는 생성(Generation) 모델로 불완전한 포인트 클라우드의 분류 성능을 향상하기 위한 핵심 단계이다. 이번 캡스톤디자인에서는 생성(Generation)에서 분류(Classification)로 이어지는 2단계 구조를 핵심

골자로 채택한다. 불완전 포인트 클라우드에서 완전한 포인트 클라우드를 생성하는 첫 번째 단계와 앞서 생성된 완전한 포인트 클라우드를 대상으로 실제 분류를 진행하는 두 번째 단계를 지니고 있다.

다. 최종결과물의 목표

포인트 클라우드 데이터셋은 Lidar 등과 같은 3D 센서의 비싼 가격과 실제 관측에서 소요되는 높은 비용, 관측된 데이터의 라벨링의 어려움 등과 같은 이유로 수집과 확보에 난해한 데이터셋으로 분류된다. 이에 따라 포인트 클라우드를 연구하는 다수의 선행 연구들은 실용적인 문제로 3D 센서로 관측된 불완전한 포인트 클라우드가 아닌 ModelNet10/40, ShapeNet, SharpNet 등과 같이 기존 3D CAD 모델에서 포인트를 임의 추출한 완전한 포인트 클라우드를 데이터셋으로 활용하고 있다. 이에 따라 학습 데이터셋은 완전한 포인트 클라우드인 반면, 테스트 데이터셋은 가려짐 현상이 발생한 불완전한 포인트 클라우드라는 문제가 발생한다. 즉 학습 데이터셋과 테스트 데이터셋의 차이가 현저히 발생하며 이는 실제 환경에서 상당한 성능 하락을 야기한다. 이번 캡스톤디자인에서는 체계적인 실험을 통해 실제 환경에서 가려짐 현상이 발생했을 때 분류 정확도의 하락 정도를 관측한다. 또한 생성에서 분류로 이어지는 2단계 구조를 도입하여 학습 데이터셋과 테스트 데이터셋의 차이로 발생하는 성능 하락 폭을 최소화한다. 이를 통해 포인트 클라우드 컴플리션을 활용하여 불완전한 포인트 클라우드의 분류 성능을 향상하는 방법에 관하여 탐구한다.

2. 과제 수행방법

실험1	완전한 포인트 클라우드로 학습된 분류기에서 불완전한 포인트 클라우드의 분류 정확도
실험2	완전한 포인트 클라우드로 학습된 분류기에서 2단계(생성->분류) 구조를 도입했을 때 불완전한 포인트 클라우드의 분류 정확도

Table1. 실험

이번 캡스톤디자인의 과제를 수행하기 위하여 다음과 같이 모두 2개의 실험을 구성하였다. **실험1**은 완전한 포인트 클라우드로 학습된 분류기가 실제 환경에서 가려짐 현상으로 인해 불완전한 포인트 클라우드를 입력으로 받았을 때 분류 정확도를 측정하기 위한 실험이며, **실험2**은 생성에서 분류로 이어지는 2단계 구조를 도입했을 때 같은 분류기에서 불완전한 포인트 클라우드의 분류 정확도를 측정하기 위한 실험이다.

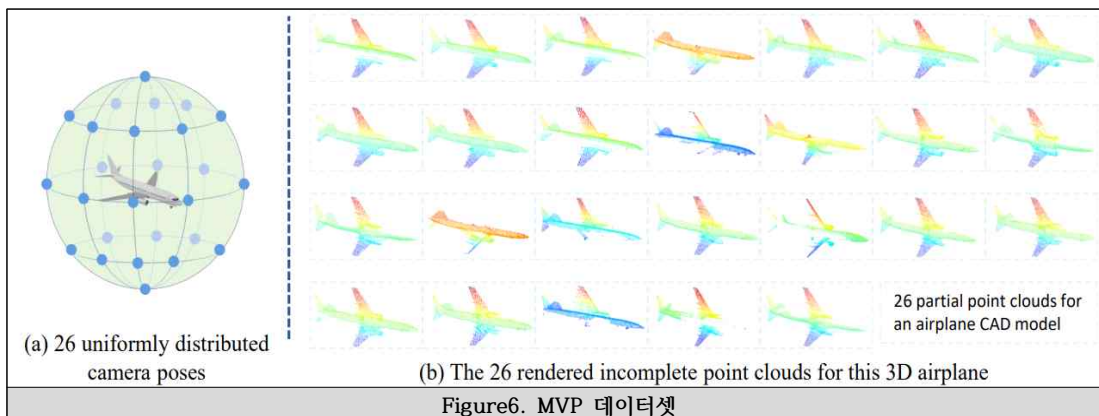


Figure6. MVP 데이터셋

실험 데이터셋은 MVP(Multi-View Partial Point Cloud) 데이터셋과 Partitioned-MVP 데이터셋을 활용하였다. MVP 데이터셋은 SharpNet 데이터셋을 변형한 불완전 포인트 클라우드 데이터셋으로 SharpNet의 완전한 포인트 클라우드를 대상으로 가상 카메라를 도입하여 26개의 균일한 각도에서 관측한 불완전한 포인트 클라우드 데이터셋이다. 모두 16개의 클래스로 이뤄져 있으며 총 80,000개의 불완전한 포인트 클라우드를 이뤄져 있다.

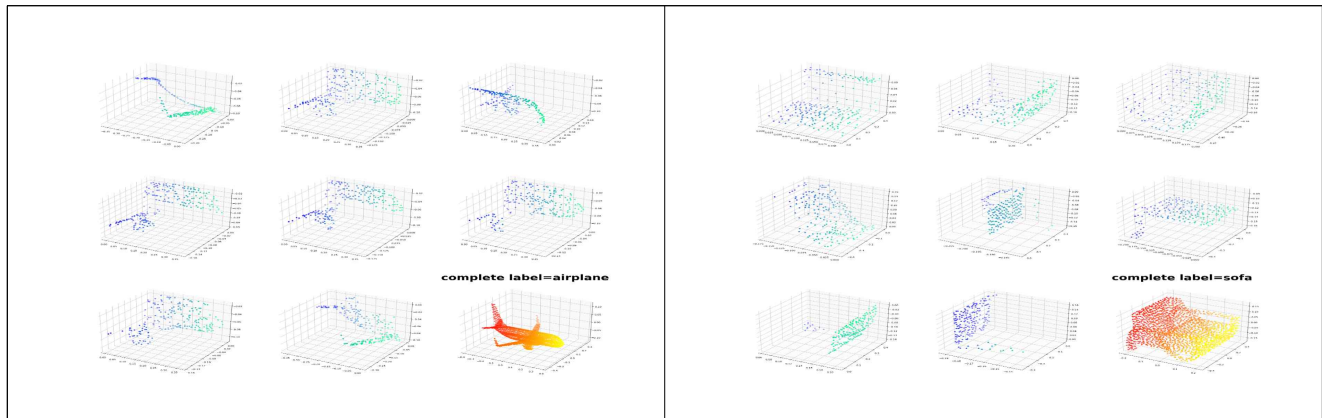


Figure7. Partitioned-MVP 데이터셋

Partitioned-MVP 데이터셋은 보다 실제 환경에서 관측한 불완전한 포인트 클라우드 유사하도록 MVP 데이터셋을 변형하여 생성한 데이터셋이다. 기존 MVP 데이터셋은 가상의 카메라를 도입하여 26개의 균일한 각도로 완전한 포인트 클라우드를 관측함으로써 Self-Occlusion이 반영한 불완전한 포인트 클라우드이지만, 실제 환경에서 발생할 수 있는 View-Occlusion과 Ambient-Occlusion 현상의 반영은 미흡하다는 단점이 있다. 따라서 Partitioned-MVP 데이터셋은 각 MVP 데이터셋의 불완전한 포인트 클라우드를 대상으로 다시 X, Y, Z 좌표의 부호를 기준으로 분할한 가려진 포인트 클라우드 데이터셋이다. 모두 16개의 클래스를 가지며, 총 80,000개의 가려진 포인트 클라우드로 이뤄져 있다.

실험1은 MVP 데이터셋과 Partitioned-MVP 데이터셋을 대상으로 이뤄졌다. MVP 데이터셋을 활용한 실험은 모두 3개로 구성하였으며 Partitioned-MVP

데이터셋	학습	테스트
MVP	완전(Complete)	완전(Complete)
	완전(Complete)	불완전(Incomplete)
	불완전(Incomplete)	불완전(Incomplete)
Partitioned-MVP	완전(Complete)	가려진(Occluded)
	가려진(Occluded)	가려진(Occluded)

Table1. 실험1

데이터셋을 활용한 실험은 모두 2개로 구성하였다. 완전한 포인트 클라우드 학습과 완전한 포인트 클라우드 테스트는 실험 대조군으로 나머지 4개는 실험 비교군으로 설정하였다. 첫 번째 실험의 분류기는 PointNet으로 선정하여 학습하였다.

실험2은 또한 다음과 같이 MVP 데이터셋과 Partitioned-MVP 데이터셋을 대상으로 이뤄졌다. 분류기는 완전한 포인트 클라우드로 사전 학습된 PointNet으로 고정하였으며, 생성기(Generator)는 PCN(Point Completion Network)으로 선정하였다. 생성기 학습을 위한 손실함수를 Cross Entropy Loss(CE)와 Chamfer

데이터셋	생성기	분류기	손실함수
MVP	불완전(Incomplete)	완전(Complete)	CE
	불완전(Incomplete)		CD
Partitioned-MVP	가려진(Occluded)		CE
	가려진(Occluded)		CD

Table2. 실험2

Distance Loss(CD)로 모두 두 가지로 나눠 학습하였다. 이에 따라 MVP 데이터셋을 활용한 두 번째 실험과 Partitioned-MVP 데이터셋을 활용한 두 번째 실험은 각각 CE와 CD로 생성기를 학습한 2개의 실험으로 이뤄지며 두 번째 실험은 총 4개의 실험으로 구성된다.

학습률, 배치 사이즈, 옵티마이저 등과 같은 실험 세부 사항은 github.com/GoDa-Choe/capstone_design에서 확인 가능하다.

3. 수행결과

가. 과제수행 결과

데이터셋	학습	테스트	분류 정확도(%)
MVP	완전(Complete)	완전(Complete)	90.06%
	완전(Complete)	불완전(Incomplete)	68.11%(21.9%p ↓)
	불완전(Incomplete)	불완전(Incomplete)	88.30%(1.76%p ↓)
Partitioned-MVP	완전(Complete)	가려진(Occluded)	12.76%(77.3%p ↓)
	가려진(Occluded)	가려진(Occluded)	84.77%(5.29%p ↓)

Table3. 실험1 결과 (분류 정확도 상승/하락 비교 기준은 대조군 90.06%)

데이터셋	분류기	생성기	손실함수	CD	분류 정확도(%)
MVP	완전(Complete)	불완전(Incomplete)	CE	-	86.71%(18.6%p ↑)
		불완전(Incomplete)	CD	11.86	86.82%(18.7%p ↑)
Partitioned-MVP		가려진(Occluded)	CE	-	83.11%(70.4%p ↑)
		가려진(Occluded)	CD	14.85	81.54%(68.8%p ↑)

Table4. 실험2 결과

(분류 정확도 상승/하락 비교 기준은 각각의 실험 1 결과, MVP 데이터셋 68.11%, Partitioned-MVP 데이터셋 12.76%, CD는 실제 값에 10,000을 곱한 값)

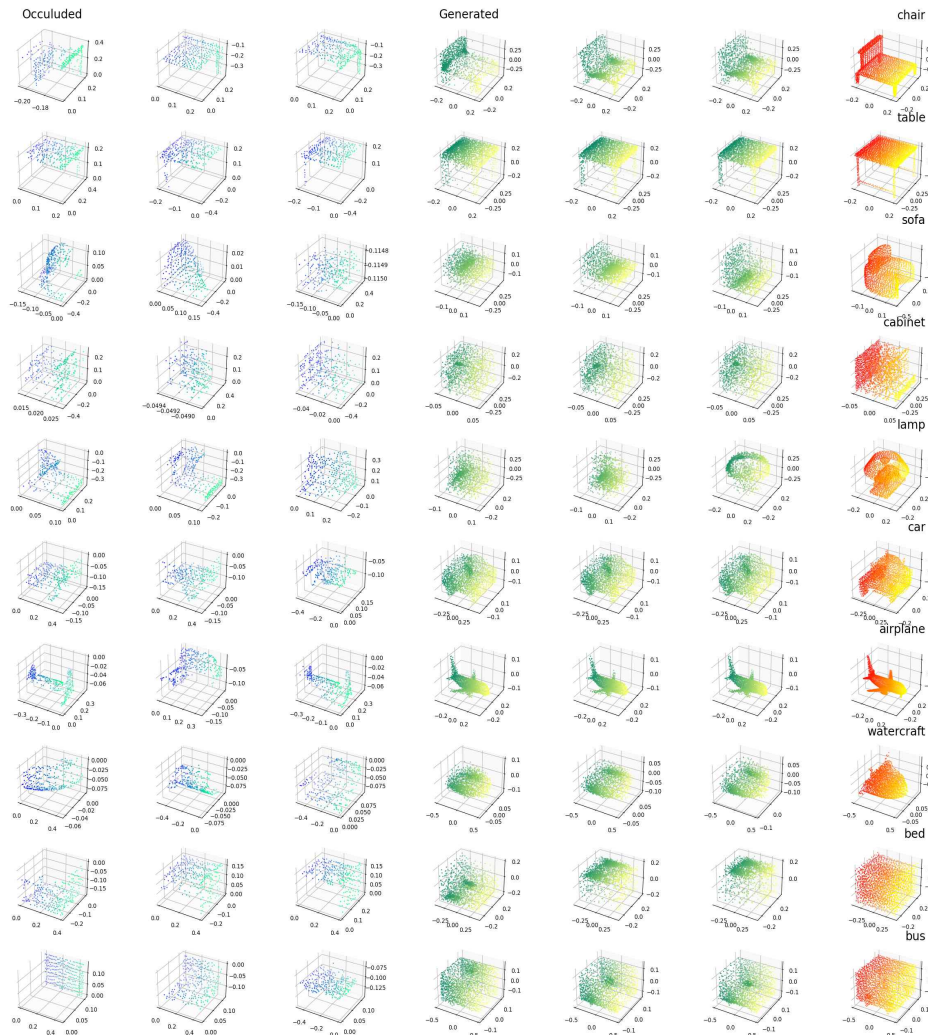


Figure8. CD로 학습했을 때의 포인트 클라우드 컴플리션 결과

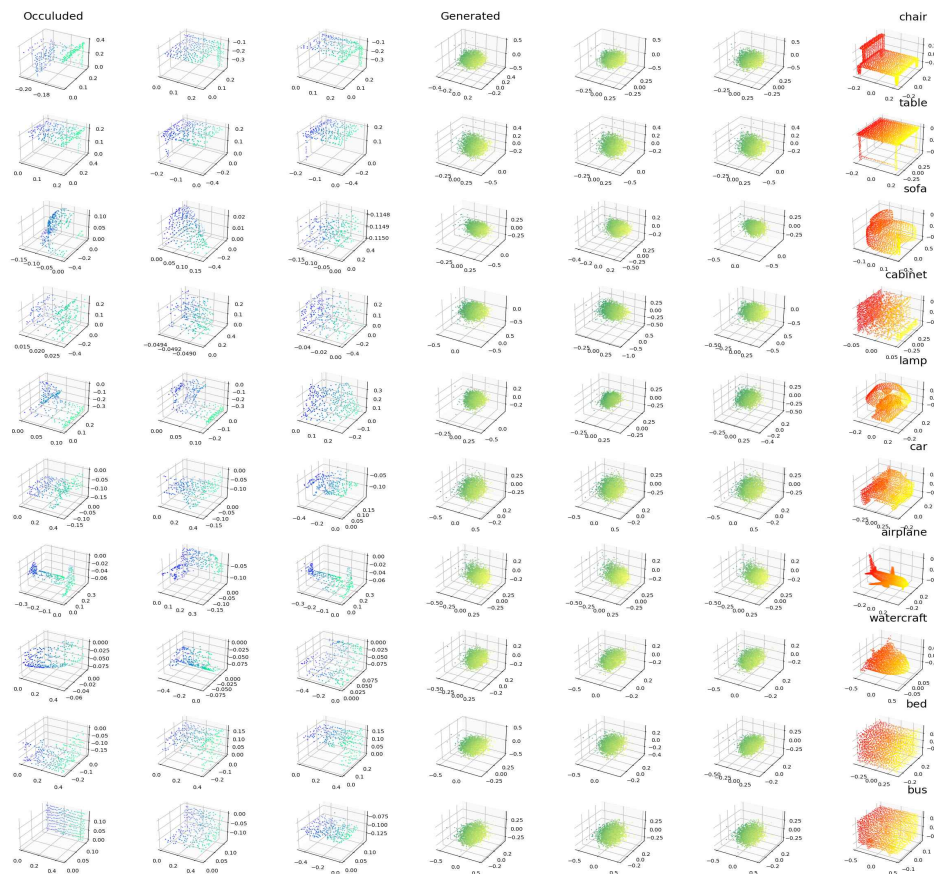


Figure9. CE로 학습했을 때의 포인트 클라우드 컴플리션 결과

나. 최종결과물 주요특징 및 설명

실험1을 수행한 결과 MVP 데이터셋에서 완전한 포인트 클라우드로 학습된 분류기에서 불완전한 포인트 클라우드의 분류 정확도는 68.11%로 측정되었다. 이는 실험 대조군 90.06%와 비교해 정확도가 21.9%p 하락한 수치이다. 또한 Partitioned-MVP 데이터셋에서는 완전한 포인트 클라우드로 학습된 분류기에서 가려진 포인트 클라우드의 분류 정확도는 12.76%로 실험 대조군과 비교해 77.3%p 하락하였다. 이를 통해 실제 환경에서 가려짐 현상으로 불완전한 포인트 클라우드가 관측되면 분류 정확도가 급격하게 하락하는 것으로 해석할 수 있다.

이러한 가려짐 문제를 해결하기 위해 이번 캡스톤디자인에서 도입한 생성에서 분류로 이어지는 2단계 구조를 도입해 **실험2**를 진행한 결과, 분류 정확도 하락을 최소화할 수 있었다. MVP 데이터셋에서 CE와 CD를 손실함수로 생성기를 학습했을 때 각각 86.7%와 86.82%로 분류 정확도가 측정되었다. 이는 생성기 없이 분류기만을 활용해 불완전한 포인트 클라우드를 분류했을 때의 정확도 68.11%와 비교해 각각 18.6%p와 18.7%p 상승하였다. 특히 Partitioned MVP 데이터셋에서 생성기를 활용했을 때 분류 정확도가 큰 폭으로 향상하였다. CE와 CD를 손실함수로 생성기를 학습했을 때 각각 83.11%와 81.54%로 분류 정확도가 측정되었다. 생성기 없이 분류기만을 활용해 가려진 포인트 클라우드를 분류했을 때의 정확도 12.76%와 비교해 각각 70.4%p와 68.8%p로 급격하게 분류 정확도가 상승하였다. 또한 주목해야할 점은 생성기가 CE로 학습되었을 때 완전한 포인트 클라우드를 정확하게 만들어내는 성능은 매우 떨어지지만, 이러한 포인트 클라우드를 대상으로 분류를 진행했을 때 정확도가 매우 높게 관측되었다는 점이다. 이는 생성기가 완전한 포인트

클라우드를 생성하기 보단, 분류가 쉬운 방향으로 불완전 포인트 클라우드를 변형(Tranform)하는 것으로 해석할 수 있다.

4. 기대효과 및 활용방안

가. 기대효과

실험 결과를 통해 완전한 포인트 클라우드로 학습된 분류기에서 가려짐 현상으로 불완전한 포인트 클라우드가 입력으로 주어졌을 때 분류 정확도가 큰 폭으로 하락하는 것을 확인할 수 있었다. 이를 해결하기 위해 이번 캡스톤디자인에서 도입한 생성에서 분류로 이어지는 2단계 구조를 활용해 불완전한 포인트 클라우드의 분류 정확도를 큰 폭으로 향상할 수 있었다. 즉 생성기를 활용하는 2단계 구조를 도입하면 실제 환경에서 Lidar 등과 같은 3D 센서로 관측한 불완전한 포인트 클라우드에서도 최소 81.54% 이상의 분류 정확도를 얻을 수 있는 것으로 나타났다.

나. 활용방안

이에 따라 불완전 포인트 클라우드가 관측되는 실제 환경에서 생성기를 적절히 활용하면 분류 문제 뿐만 아니라 3D Segmentation, 3D Detection 등과 같은 다양한 컴퓨터비전 문제를 해결할 수 있을 것으로 기대된다.

5. 결론 및 제언

이번 캡스톤디자인을 통해 완전한 포인트 클라우드로 학습된 분류기는 가려짐 현상이 발생하는 실제 환경에서 적절한 분류 성능을 내지 못하는 것을 **실험1**을 통해 확인했다. 이는 학습 데이터셋은 완전한 포인트 클라우드인 것에 반해 테스트 데이터셋은 불완전한 포인트 클라우드로 학습 데이터셋과 테스트 데이터셋의 차이로 야기되는 문제로 해석할 수 있다. 더구나 Self-Occlusion은 단일 3D 센서로 관측할 경우 나타나는 불가피한 현상이기 때문에 실제 환경에서 관측 가능한 포인트 클라우드는 필연적으로 불완전할 수밖에 없다. 즉 분류기만을 활용했을 때는 실제 환경에서는 실용적인 분류 정확도를 기대할 수 없다. 그러나 **실험2**를 통해 포인트 클라우드 컴플리션을 활용하면 이러한 문제를 상당 부분 해결할 수 있었다. 생성에서 분류로 이어지는 2단계 구조를 도입하면 불완전한 포인트 클라우드에서도 최소 81.54% 이상의 분류 정확도를 얻을 수 있었다. 이를 통해 생성 모델을 활용하면 완전한 포인트 클라우드로 학습된 분류기에서도 불완전한 포인트 클라우드의 분류 정확도를 신뢰할 수 있는 수준까지 향상할 수 있었다.

그러나 분류기를 불완전한 포인트 클라우드로 학습하는 분류기 단일 방법에서의 분류 정확도는 MVP 데이터셋과 Partitioned-MVP 데이터셋에서 각각 88.30%와 84.77%로 이번 캡스톤디자인에서 제안한 생성-분류 2단계 구조보다 각각 1.48%p와 1.66% 높은 분류 정확도를 보였다. 이는 포인트 클라우드 컴플리션을 활용하는 불완전한 포인트 클라우드의 분류 성능의 한계로 뽑을 수 있다.

하지만 불완전한 포인트 클라우드는 Lidar 등과 같은 3D 센서의 비싼 가격과, 실제 관측의 높은 비용, 라벨링의 어려움 등과 같은 이유로 다량의 데이터셋을 모으는 것은 현실적으로 어려움이 존재한다. 이에 따라 ModelNet, ShapeNet, SharpNet 등과 같이 포인트 클라우드를 주제로 하는 대다수의 연구들은 기존 3D CAD 모델에서 포인트를 임의 추출한 완전한 포인트 클라우드 데이터셋을 활용하고 있다. 즉 데이터셋 확보 관점에서 불완전한 포인트 클라우드로 분류 모델을 학습하는 것은 한계가 존재한다. 또한 불완전한 포인트 클라우드는 3차원 정보의 손실을 내재하고 있다. 이러한 정보의 손실은 포인트 클라우드가 사물의 기하학적 모양과 규모 등 3차원 정보를 그 자체로 온전히 표현하고 있다는 장점을 훼손하게 된다. 따라서 불완전한 포인트 클라우드는 양적으로나 질적으로 데이터셋의 확보가 현실적으로 어려우며 3차원 정보의 손실이 불가피하기 때문에 실용적인 학습 대상이 될 수 없다.

※ 본 양식은 요약보고서이며, 최종결과물을 필히 추가 제출하여야 함.

팀 학생대표 성명 :

최민기

이현기